

UNIVERSIDAD LA SALLE

Ingeniería en Software

Minería de Datos

Análisis exploratorio y reducción de dimensiones mediante componentes principales del conjunto de datos Wisconsin Diagnostic Breast Cancer

Alumno

Marcos Castro Cruz

Profesor

Maritza Fabiola Leon Bejarano

Oaxaca de Juárez, Oaxaca

12 de septiembre de 2026

Análisis exploratorio y reducción de dimensiones mediante componentes principales del conjunto de datos Wisconsin Diagnostic Breast Cancer

Marcos Castro Cruz

Este trabajo presenta el análisis exploratorio y la reducción de dimensiones del conjunto de datos Wisconsin Diagnostic Breast Cancer, formado por 569 registros y 32 columnas. Primero se identificaron los tipos de datos y se separaron las variables cualitativas de las cuantitativas; después se revisó la calidad del conjunto y se calcularon medidas de tendencia central y de dispersión, acompañadas de histogramas, diagramas de caja y gráficas de dispersión. El estudio mostró que las variables están expresadas en escalas muy distintas y que muchas de ellas miden prácticamente lo mismo, ya que 21 de los 435 pares posibles superan una correlación de 0.90. Por esa razón se estandarizaron los datos y se aplicó el análisis de componentes principales. Los dos primeros componentes reúnen el 63.24 % de la información original, se requieren cinco componentes para llegar al 80 % y siete para alcanzar el 90 %. El primer componente resume el tamaño y la irregularidad del contorno de los núcleos celulares, mientras que el segundo se relaciona con la complejidad de la forma frente al tamaño. La proyección de los casos sobre los dos primeros componentes separa de manera clara los diagnósticos benignos de los malignos.

Índice de Términos— análisis de componentes principales, correlación, escalamiento, estadística descriptiva, minería de datos.

I. INTRODUCCIÓN

El primer paso de cualquier proyecto de minería de datos consiste en conocer a fondo la información con la que se va a trabajar. Antes de construir un modelo es necesario saber qué representa cada columna, en qué unidades está medida, si contiene errores o vacíos y qué relación guarda con las demás. Esta etapa se conoce como análisis exploratorio de datos y fue propuesta formalmente por Tukey como una forma de dejar que los datos muestren su propia estructura antes de imponerles supuestos [7].

Cuando un conjunto de datos tiene muchas columnas aparece un problema adicional. Si varias variables describen el mismo fenómeno desde ángulos parecidos, la información se repite, las gráficas se vuelven difíciles de leer y los modelos pierden estabilidad. Una alternativa muy utilizada para resolverlo es el análisis de componentes principales, conocido por sus siglas en inglés como PCA, que construye nuevas variables a partir de combinaciones de las originales y concentra en las primeras la mayor cantidad posible de variación [5], [12].

El conjunto de datos utilizado en este reporte es el Wisconsin Diagnostic Breast Cancer, generado por Street, Wolberg y Mangasarian a partir de imágenes digitalizadas de muestras obtenidas mediante punción con aguja fina [1]. Cada registro describe con treinta medidas la forma y la textura de los núcleos celulares observados en una imagen, e incluye el diagnóstico correspondiente. El conjunto está disponible públicamente en el repositorio de aprendizaje automático de la Universidad de California en Irvine [2], [3].

El objetivo de este trabajo es doble. Por una parte, describir el conjunto de datos con herramientas de estadística descriptiva y gráficas que permitan reconocer patrones y posibles problemas de calidad. Por otra, aplicar un escalamiento y un análisis de componentes principales para determinar cuántas dimensiones son realmente necesarias para representar la información sin perder una parte importante de ella.

II. DESCRIPCIÓN DEL CONJUNTO DE DATOS

A. Origen y estructura

El archivo *wdbc.data* contiene 569 renglones y 32 columnas. El primer campo es un número de identificación del paciente, el segundo es el diagnóstico y los treinta restantes son medidas numéricas calculadas sobre la imagen. Estas treinta columnas no son treinta características distintas, sino diez características básicas medidas de tres formas diferentes: el valor promedio de todos los núcleos de la imagen, el error estándar de esa medición y el valor de los tres núcleos más

grandes, al que la documentación original llama valor peor [1].

Las diez características básicas son el radio, la textura, el perímetro, el área, la suavidad, la compacidad, la concavidad, los puntos cóncavos, la simetría y la dimensión fractal. Al combinarse con los tres tipos de medición dan como resultado las treinta variables que se resumen en la Tabla I.

TABLA I
ESTRUCTURA DE LAS VARIABLES DEL CONJUNTO DE DATOS

Columna	Contenido	Tipo de dato	Clasificación	Escala
1	Número de identificación	Entero	Cualitativa	Nominal
2	Diagnóstico (B o M)	Texto	Cualitativa	Nominal
3–12	Diez características, valor promedio	Decimal	Cuantitativa continua	De razón
13–22	Diez características, error estándar	Decimal	Cuantitativa continua	De razón
23–32	Diez características, valor peor	Decimal	Cuantitativa continua	De razón

B. Variables cualitativas y cuantitativas

Las variables cualitativas son aquellas que expresan una cualidad o categoría y no admiten operaciones aritméticas con sentido. En este conjunto hay dos. La primera es el número de identificación, que aunque se almacena como número entero funciona sólo como etiqueta: no tiene sentido calcular su promedio. La segunda es el diagnóstico, que toma los valores B para benigno y M para maligno; se trata de una variable nominal con dos categorías.

Las treinta variables restantes son cuantitativas continuas. Todas pueden tomar cualquier valor dentro de un intervalo y admiten operaciones aritméticas. Además pertenecen a una escala de razón, porque el cero representa la ausencia real de la magnitud medida y los cocientes entre valores tienen interpretación: un área de 1000 es efectivamente el doble que una de 500. Esta distinción entre escalas nominales, ordinales, de intervalo y de razón corresponde a la clasificación clásica de Stevens [13] y determina qué estadísticos y qué gráficas resultan adecuados en cada caso [4].




Fig. 1. Distribución de la variable cualitativa diagnóstico. El conjunto contiene más casos benignos que malignos, con una proporción aproximada de tres a dos.

C. Calidad de los datos

La revisión de calidad se concentró en cuatro aspectos. En primer lugar, la presencia de valores faltantes: el conjunto no tiene ninguno, lo que coincide con lo señalado en la documentación original. En segundo lugar, los registros repetidos: no existen renglones duplicados ni identificadores repetidos, por lo que cada caso corresponde a un paciente distinto.

El tercer aspecto se refiere a los valores en cero. Trece registros tienen cero en las variables de concavidad y de puntos cóncavos, en sus tres versiones. No se trata de un error de captura sino de un caso legítimo: son núcleos cuyo contorno no presenta hundimientos, de modo que el valor cero significa ausencia de la característica. Aun así conviene tenerlo presente, porque impide aplicar transformaciones como el logaritmo sin un ajuste previo.

El cuarto aspecto son los valores atípicos. Aplicando el criterio de Tukey, que marca como atípico todo dato que se aleja más de 1.5 veces el rango intercuartílico por debajo del primer cuartil o por encima del tercero [7], se detectaron 608 valores extremos, equivalentes al 3.56 % de todas las celdas numéricas. La variable con más casos extremos es el área en su versión de error estándar, con 65. Estos valores no se eliminaron, porque corresponden a tumores de gran tamaño que son justamente los casos clínicamente relevantes; su presencia, sin embargo, explica la fuerte asimetría que se observa después en los histogramas.

```
import pandas as pd

base = ["radio", "textura", "perimetro", "area", "suavidad", "compacidad",
        "concavidad", "puntos_concavos", "simetria", "dimension_fractal"]
sufijos = ["media", "ee", "peor"]
variables = [f"{b}_{s}" for s in sufijos for b in base]
columnas = ["id", "diagnostico"] + variables

df = pd.read_csv("wdbc.data", header=None, names=columnas)
X = df[variables]
y = df["diagnostico"]
```

Código 1. Carga del archivo y asignación de los nombres de las columnas.

IV. EXPLORACIÓN INICIAL Y ESTADÍSTICA DESCRIPTIVA

A. Distribución de la variable cualitativa

De los 569 casos, 357 corresponden a tumores benignos, es decir el 62.74 %, y 212 a tumores malignos, el 37.26 % restante, como se aprecia en la Fig. 1. El desbalance existe pero es moderado, de manera que ninguna de las dos categorías queda subrepresentada al punto de dificultar el análisis.

Un último detalle de calidad es de forma más que de contenido: el archivo no incluye los nombres de las columnas, que deben tomarse del documento *wdbc.names* y asignarse manualmente al momento de la carga.

III. METODOLOGÍA

El análisis se realizó en Python. Se utilizó la biblioteca *pandas* para la carga y el manejo de la tabla [9], *NumPy* para los cálculos numéricos [10], *Matplotlib* para las gráficas [11] y *scikit-learn* para el escalamiento y el análisis de componentes principales [8]. El procedimiento siguió seis etapas: carga y nombrado de las columnas, revisión de la estructura y la calidad, cálculo de estadísticas descriptivas, exploración gráfica, estandarización de las variables y aplicación del PCA.

El Código 1 muestra la carga del archivo y la construcción de los nombres de las columnas a partir de las diez características básicas y los tres tipos de medición.

B. Medidas de tendencia central y de dispersión

Para cada variable numérica se calcularon la media, la mediana, la desviación estándar, el rango, el rango intercuartílico y el coeficiente de variación. Este último expresa la desviación estándar como porcentaje de la media y permite comparar la dispersión de variables medidas en unidades distintas [4]. La Tabla II resume los resultados de las diez variables promedio.

TABLA II
ESTADÍSTICAS DESCRIPTIVAS DE LAS DIEZ VARIABLES PROMEDIO

Variable	Media	Mediana	Desv. est.	Mínimo	Máximo	CV (%)	Asimetría
radio	14.127	13.370	3.524	6.981	28.110	24.95	0.942
textura	19.290	18.840	4.301	9.710	39.280	22.30	0.650
perímetro	91.969	86.240	24.299	43.790	188.500	26.42	0.991
área	654.889	551.100	351.914	143.500	2501.000	53.74	1.646
suavidad	0.0964	0.0959	0.0141	0.0526	0.1634	14.60	0.456
compacidad	0.1043	0.0926	0.0528	0.0194	0.3454	50.62	1.190
concavidad	0.0888	0.0615	0.0797	0.0000	0.4268	89.78	1.401
puntos cóncavos	0.0489	0.0335	0.0388	0.0000	0.2012	79.32	1.171
simetría	0.1812	0.1792	0.0274	0.1060	0.3040	15.13	0.726
dim. fractal	0.0628	0.0615	0.0071	0.0500	0.0974	11.24	1.304

```
desc = pd.DataFrame({
    "media": X.mean(),
    "mediana": X.median(),
    "desv est": X.std(),
    "rango": X.max() - X.min(),
    "IQR": X.quantile(0.75) - X.quantile(0.25),
    "CV_pct": X.std() / X.mean() * 100,
    "asimetría": X.skew(),
})
```

Código 2. Cálculo de las medidas de tendencia central y de dispersión.

Un primer hallazgo se obtiene comparando la media con la mediana. En casi todas las variables la media es mayor que la mediana y la asimetría es positiva, lo que indica distribuciones con una cola hacia la derecha: la mayoría de los casos se concentra en valores bajos y unos cuantos alcanzan valores muy altos. El caso más marcado es el área promedio, cuya media de 654.9 supera por más de cien unidades a su mediana de 551.1.

¿Las variables se expresan en la misma escala?

No, y la diferencia es enorme. Las medias van desde 0.0038 en el error estándar de la dimensión fractal hasta 880.58 en el área peor, una diferencia de más de cinco órdenes de magnitud. Las áreas se miden en cientos o miles de unidades, los radios y perímetros en decenas, y las medidas de forma como la suavidad o la dimensión fractal en centésimas. Esta disparidad es determinante: cualquier técnica basada en distancias o en varianzas, como el PCA, quedaría dominada por las variables de mayor magnitud si no se corrigiera antes [5], [8].

¿Qué variable presenta mayor variabilidad?

La respuesta depende de cómo se mida. En términos absolutos la mayor varianza corresponde al área peor, con 324 167.4, simplemente porque es la variable con los números más grandes. Esa comparación no es justa entre escalas distintas. Usando el coeficiente de variación, que sí es comparable, la variable más dispersa es el error estándar del área, con 112.78 %, seguida por el error estándar de la concavidad con 94.65 % y la concavidad promedio con 89.78 %. En el extremo opuesto, la dimensión fractal promedio es la más estable, con apenas 11.24 %. En otras palabras, las medidas de tamaño y de concavidad varían mucho de un paciente a otro, mientras que las de forma se mantienen dentro de márgenes estrechos.

C. Histogramas

La Fig. 2 presenta los histogramas de las diez variables promedio, con la media y la mediana señaladas. Se confirma lo que anticipaban las estadísticas: el radio, el perímetro, el área, la compacidad, la concavidad y los puntos cóncavos muestran distribuciones claramente sesgadas

hacia la derecha. La suavidad, la simetría y la textura, en cambio, se aproximan bastante a una forma simétrica.




Fig. 2. Histogramas de las diez variables promedio. La línea continua marca la media y la discontinua la mediana; la distancia entre ambas revela la asimetría de cada distribución.

En varias variables el histograma sugiere la presencia de dos grupos superpuestos. La Fig. 3 separa las distribuciones por diagnóstico y confirma esa intuición: en el radio promedio, el área peor y los puntos cóncavos promedio, los casos benignos se concentran en los valores bajos

y los malignos se desplazan hacia la derecha. Las curvas se traslapan, pero el corrimiento es evidente y anticipa que estas variables llevan información útil para distinguir ambos tipos de tumor.

D. Diagramas de caja

La Fig. 4 compara las treinta variables antes y después del escalamiento. En la parte superior, dibujada en escala logarítmica para que todas quepan en una misma imagen, las cajas aparecen a alturas muy distintas: es la representación visual de la diferencia de escalas comentada antes. Las

líneas verticales largas de las variables de concavidad y puntos cóncavos corresponden a los trece registros con valor cero. En la parte inferior, ya estandarizadas, todas las cajas quedan centradas en cero y con una amplitud comparable.

Comparación de distribuciones por diagnóstico




Fig. 3. Comparación de las distribuciones de tres variables según el diagnóstico. Los casos malignos se desplazan de manera sistemática hacia los valores altos.




Fig. 4. Diagramas de caja de las treinta variables antes (arriba, en escala logarítmica) y después (abajo) del escalamiento. La diferencia de alturas en la gráfica superior refleja la disparidad de escalas.

Los diagramas de caja también permiten comparar grupos. La Fig. 5 muestra cuatro variables separadas por diagnóstico. En el radio promedio y en los puntos cóncavos peores las cajas de ambos grupos casi no se traslapan, lo que indica una diferencia marcada. En la textura promedio la separación es parcial y en la suavidad promedio las cajas se superponen en buena medida, señal de que esa variable por sí sola distingue poco entre un diagnóstico y otro.

E. Gráficas de dispersión

Las gráficas de dispersión de la Fig. 6 muestran cómo se relacionan pares de variables. El primer

panel es contundente: el radio y el perímetro promedio forman prácticamente una línea recta, con un coeficiente de correlación de 0.998. Esto tiene una explicación geométrica sencilla, ya que el perímetro de una figura aproximadamente circular es proporcional a su radio, de modo que ambas columnas están midiendo lo mismo. El segundo panel, radio contra área, muestra una relación igual de fuerte pero curva, como corresponde a una proporción cuadrática.

Los dos paneles restantes ofrecen el contraste. El radio frente a la textura produce una nube dispersa sin tendencia definida, y lo mismo ocurre con la suavidad frente a la dimensión fractal. Estas

parejas sí aportan información independiente. Además, en todos los paneles el color permite ver que los casos malignos tienden a ocupar la zona de valores altos.

F. Correlación entre variables

La Fig. 7 presenta la matriz de correlación completa. Los bloques rojos oscuros agrupan a las

variables que se mueven juntas y revelan tres conjuntos bien definidos: el de tamaño, formado por radio, perímetro y área; el de irregularidad del contorno, formado por compacidad, concavidad y puntos cóncavos; y el de las medidas de forma, que se comportan de manera más independiente.

Diagramas de caja por tipo de diagnóstico




Fig. 5. Diagramas de caja de cuatro variables separadas por diagnóstico. El traslape entre cajas indica qué tanto distingue cada variable a los dos grupos.

Relación entre pares de variables




Fig. 6. Gráficas de dispersión de cuatro pares de variables con su coeficiente de correlación. Los dos primeros paneles muestran redundancia y los dos últimos independencia.




Fig. 7. Matriz de correlación de las treinta variables. Los bloques rojos agrupan variables que se mueven juntas y revelan tres conjuntos temáticos.

TABLA III
PARES DE VARIABLES CON MAYOR CORRELACIÓN LINEAL

Variable 1	Variable 2	r de Pearson
radio media	perímetro media	0.9979
radio peor	perímetro peor	0.9937
radio media	área media	0.9874
perímetro media	área media	0.9865
radio peor	área peor	0.9840
perímetro peor	área peor	0.9776
radio ee	perímetro ee	0.9728
perímetro media	perímetro peor	0.9704
radio media	radio peor	0.9695
dimensión fractal media	radio ee	0.0001

¿Existen variables fuertemente correlacionadas? Sí, y en gran número. De los 435 pares posibles, 44 superan un coeficiente absoluto de 0.80 y 21 rebasan 0.90, valores que se consideran de correlación muy fuerte [16]. La Tabla III recoge los casos más extremos junto con el par menos relacionado del conjunto, incluido como referencia.

¿Todas las variables aportan información diferente? No. Cuando dos columnas presentan una correlación de 0.99, conocer una permite predecir la otra casi con exactitud, de modo que la segunda casi no agrega información nueva. Esto ocurre tanto por razones geométricas, como en el caso del radio y el perímetro, como por la forma en que se construyó el conjunto, ya que el valor promedio y el valor peor de una misma característica están calculados sobre los mismos núcleos. El resultado es que las treinta columnas contienen bastante menos información de la que su número sugiere, y esa redundancia es precisamente lo que el análisis de componentes principales aprovecha.

V. ESCALAMIENTO DE LAS VARIABLES

Antes de aplicar el PCA es indispensable llevar todas las variables a una escala común. La razón es que el método busca las direcciones de máxima varianza, y la varianza depende de las unidades de medida. Si se aplicara sobre los datos originales, el área peor, con una varianza de 324 167, dominaría por completo el resultado frente a la dimensión fractal, cuya varianza es cercana a 0.0000005, no porque sea más informativa sino porque está medida en números más grandes [5], [6].

Se utilizó la estandarización, que a cada valor le resta la media de su columna y lo divide entre la desviación estándar. Después de la transformación todas las variables tienen media cero y desviación estándar uno, como se comprobó numéricamente y se aprecia en la parte inferior de la Fig. 4. Con ello, aplicar el PCA sobre los datos estandarizados equivale a trabajar con la matriz de correlación en lugar de la de covarianza, que es la práctica recomendada cuando las unidades son heterogéneas [6], [12].

```
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
import numpy as np

escalador = StandardScaler()
X_esc = escalador.fit_transform(X)

pca = PCA()
scores = pca.fit_transform(X_esc)
var_exp = pca.explained_variance_ratio_
var_acum = np.cumsum(var_exp)

n_80 = np.argmax(var_acum >= 0.80) + 1
n_90 = np.argmax(var_acum >= 0.90) + 1
```

Código 3. Escalamiento de las variables y aplicación del análisis de componentes principales.

VI. ANÁLISIS DE COMPONENTES PRINCIPALES

A. Varianza explicada por cada componente

El PCA construye nuevas variables, llamadas componentes principales, que son combinaciones de las originales. El primer componente es la

dirección en la que los datos se extienden más; el segundo es la dirección que más varianza recoge entre las que son perpendiculares a la primera, y así sucesivamente [5], [12]. La Tabla IV presenta la varianza que explica cada uno de los diez primeros componentes y la suma acumulada.

TABLA IV
VARIANZA EXPLICADA POR LOS DIEZ PRIMEROS COMPONENTES

Componente	Autovalor	Varianza explicada (%)	Varianza acumulada (%)
PC1	13.305	44.27	44.27
PC2	5.701	18.97	63.24
PC3	2.823	9.39	72.64
PC4	1.984	6.60	79.24
PC5	1.652	5.50	84.73
PC6	1.210	4.03	88.76
PC7	0.676	2.25	91.01
PC8	0.478	1.59	92.60
PC9	0.418	1.39	93.99
PC10	0.351	1.17	95.16




Fig. 8. Varianza explicada por cada componente (izquierda) y varianza acumulada con los umbrales de 80 % y 90 % señalados (derecha).

¿Cuál es la varianza explicada de cada componente? El primer componente concentra el 44.27 % de la variación total, una proporción muy alta que confirma la fuerte redundancia detectada en la matriz de correlación. El segundo aporta 18.97 %, el tercero 9.39 % y a partir del cuarto la contribución individual cae por debajo del 7 %. La Fig. 8 muestra este comportamiento en la gráfica de sedimentación, donde se aprecia el codo característico entre el segundo y el tercer componente [15].

B. Número de componentes necesarios

¿Cuál es la varianza acumulada? La columna derecha de la Tabla IV y la gráfica derecha de la Fig. 8 responden esta pregunta. Con dos

componentes se alcanza 63.24 %, con tres 72.64 %, con cuatro 79.24 % y con cinco 84.73 %.

¿Cuántas componentes se necesitan para explicar al menos el 80 %? Cinco. Con cuatro apenas se llega a 79.24 %, ligeramente por debajo del umbral, de modo que el quinto componente es el que permite superarlo. Con esas cinco variables nuevas se conserva casi el 85 % de la información original, reduciendo el número de dimensiones de treinta a cinco, es decir, a una sexta parte.

¿Cuántas se necesitan para alcanzar el 90 %? Siete, ya que la suma acumulada llega a 91.01 % en el séptimo componente frente al 88.76 % del sexto. Conviene notar que pasar del 80 % al 90 % cuesta dos componentes adicionales que aportan poco más de seis puntos porcentuales, lo que

ilustra el rendimiento decreciente de seguir agregando dimensiones.

Un criterio alternativo es el de Kaiser, que recomienda conservar los componentes con autovalor mayor que uno, es decir, aquellos que explican más varianza que una variable original estandarizada [14]. En este caso son seis, una cifra intermedia entre las dos anteriores y coherente con ellas.

¿Es suficiente representar los datos con dos componentes? Depende del propósito. Para visualizar el conjunto en un plano, dos componentes son más que suficientes y, como se verá adelante, ofrecen una imagen muy clara de la

estructura de los datos. Para un análisis cuantitativo, en cambio, quedarse con dos implica descartar casi el 37 % de la variación, una pérdida difícil de justificar. Lo recomendable es usar dos componentes para explorar y cinco o seis si el resultado alimentará un modelo posterior.

C. Interpretación de los componentes

Cada componente se forma multiplicando las variables originales por unos coeficientes llamados cargas. Una carga grande en valor absoluto significa que esa variable pesa mucho en el componente; el signo indica la dirección de esa influencia. La Tabla V y la Fig. 9 presentan las cargas de los dos primeros componentes.

TABLA V
VARIABLES CON MAYOR PESO ABSOLUTO EN LOS DOS PRIMEROS COMPONENTES

Variable en PC1	Carga	Variable en PC2	Carga
puntos cóncavos media	0.2609	dimensión fractal media	0.3666
concavidad media	0.2584	dimensión fractal ee	0.2801
puntos cóncavos peor	0.2509	dimensión fractal peor	0.2753
compacidad media	0.2393	radio media	-0.2339
perímetro peor	0.2366	compacidad ee	0.2327
concavidad peor	0.2288	área media	-0.2311
radio peor	0.2280	radio peor	-0.2199
perímetro media	0.2275	área peor	-0.2194
área peor	0.2249	perímetro media	-0.2152
área media	0.2210	suavidad ee	0.2044




Fig. 9. Cargas de las treinta variables sobre los dos primeros componentes. En PC1 todas son positivas y de magnitud parecida; en PC2 aparecen signos opuestos.

¿Qué variables tienen mayor peso absoluto en PC1? Los puntos cóncavos promedio con 0.2609, la concavidad promedio con 0.2584, los puntos cóncavos peores con 0.2509 y la compacidad promedio con 0.2393. Inmediatamente después aparecen el perímetro peor, la concavidad peor, el radio peor y el perímetro promedio, todos alrededor de 0.23. Lo más revelador es que las cargas están muy repartidas y todas son positivas, sin que ninguna variable domine. En el otro extremo, las que menos pesan son el error estándar de la suavidad con 0.0145 y el de la textura con 0.0174, cuya contribución es prácticamente nula.

¿Qué variables tienen mayor peso absoluto en PC2? Aquí el panorama cambia. Encabeza la lista la dimensión fractal promedio con 0.3666, seguida por la dimensión fractal en su versión de error estándar con 0.2801 y en su versión peor con

0.2753. Enseguida aparecen, con signo negativo, el radio promedio con -0.2339 , el área promedio con -0.2311 y el radio peor con -0.2199 . La convivencia de signos opuestos es justamente lo que distingue a este componente.

¿Qué variables del dataset representa PC1? Representa al conjunto de variables relacionadas con el tamaño del núcleo y con la irregularidad de su contorno, es decir, radio, perímetro, área, compacidad, concavidad y puntos cóncavos, en sus tres versiones. Prácticamente no representa a las medidas de variabilidad interna como el error estándar de la suavidad o de la textura.

¿Cómo se podría interpretar conceptualmente PC1? Como un indicador general de gravedad del tumor. Al ser todas sus cargas positivas y de magnitud similar, el componente funciona como un promedio ponderado de casi todas las

mediciones: un valor alto corresponde a un núcleo grande, con contorno irregular y muchos hundimientos, mientras que un valor bajo corresponde a un núcleo pequeño y de contorno suave. Este comportamiento es típico del primer componente cuando las variables están positivamente correlacionadas entre sí, y suele denominarse factor de tamaño o factor general [6], [12].

El segundo componente admite una lectura distinta. Al oponer la dimensión fractal, que mide qué tan complejo y rugoso es el borde, a las variables de tamaño como el radio y el área, PC2 contrasta la complejidad de la forma con la magnitud del núcleo. Un valor alto describe núcleos pequeños pero de contorno intrincado;

uno bajo, núcleos grandes de contorno más liso. En términos prácticos, PC1 indica cuánto mide el núcleo y PC2 qué tan complicada es su forma en relación con ese tamaño.

D. Proyección de los objetos sobre los componentes

La Fig. 10 muestra los 569 casos proyectados sobre los dos primeros componentes, coloreados según su diagnóstico. La separación es notable: los casos benignos se agrupan en la mitad izquierda, con una media de -2.206 en PC1, mientras que los malignos se desplazan hacia la derecha, con una media de 3.715 . La frontera entre ambos grupos es difusa y existe una zona central de traslape, pero la tendencia resulta inequívoca.




Fig. 10. Proyección de los 569 casos sobre los dos primeros componentes principales, coloreados según el diagnóstico. Los casos benignos ocupan la mitad izquierda y los malignos la derecha.

Conviene subrayar que el PCA no utilizó en ningún momento la columna de diagnóstico: es una técnica no supervisada que sólo observa las treinta variables numéricas. Que la separación aparezca de todos modos significa que la diferencia entre tumores benignos y malignos es la fuente principal de variación del conjunto, lo

cual respalda la interpretación de PC1 como indicador de gravedad.

Sobre el eje vertical la separación es mucho menor, con medias de 0.346 para los casos benignos y -0.583 para los malignos. PC2 aporta entonces matices sobre la forma del núcleo más que una distinción diagnóstica. El biplot de la Fig. 11 combina ambas lecturas: las flechas indican

hacia dónde crece cada variable original y confirman que las medidas de concavidad y

tamaño apuntan hacia la región ocupada por los casos malignos.




Fig. 11. Biplot con los casos y las variables de mayor peso. Las flechas indican la dirección de crecimiento de cada variable original.

```
import matplotlib.pyplot as plt

fig, ax = plt.subplots(figsize=(4.6, 3.6))
for clase, color, etiqueta in [("B", "#3B6E8F", "Benigno"), ("M", "#B5433A", "Maligno")]:
    m = y == clase
    ax.scatter(scores[m, 0], scores[m, 1], s=14, alpha=0.7, color=color, label=etiqueta)

ax.set_xlabel(f"PC1 ({var_exp[0]*100:.2f} % de la varianza)")
ax.set_ylabel(f"PC2 ({var_exp[1]*100:.2f} % de la varianza)")
ax.legend()
fig.savefig("scores_pca.png", dpi=200, bbox_inches="tight")
```

Código 4. Generación de la gráfica de dispersión de los scores sobre los dos primeros componentes.

VII. DISCUSIÓN DE RESULTADOS

El recorrido completo deja ver una idea central: un conjunto con treinta columnas no necesariamente contiene treinta piezas de información distintas. La exploración descriptiva mostró escalas muy dispares y una redundancia considerable entre columnas, y el análisis de componentes principales cuantificó esa redundancia al concentrar casi la mitad de la variación total en una sola dirección.

También quedó claro que el escalamiento no es un paso opcional. Sin él, el resultado del PCA habría reflejado sobre todo las unidades de medida del área y no la estructura real de los datos. Este detalle, que suele pasarse por alto, condiciona por completo la validez del análisis.

Finalmente, la interpretación de los componentes muestra el valor añadido de la técnica. PC1 y PC2 no son combinaciones arbitrarias de números: tienen un significado que puede expresarse en palabras, el tamaño e irregularidad del núcleo en el primer caso y la complejidad de la forma en el segundo. Esa

capacidad de traducir un resultado matemático a un concepto comprensible es lo que convierte al PCA en una herramienta de análisis y no sólo en un procedimiento de compresión.

Entre las limitaciones del trabajo conviene mencionar dos. La primera es que el PCA sólo capta relaciones lineales, de modo que un vínculo curvo como el que existe entre el radio y el área se representa de forma aproximada. La segunda es que los componentes, al mezclar todas las variables originales, son más difíciles de explicar ante un especialista que las mediciones directas, lo que supone un costo en interpretabilidad que debe valorarse según el uso previsto.

VIII. CONCLUSIONES

El conjunto Wisconsin Diagnostic Breast Cancer contiene 569 registros, dos variables cualitativas nominales y treinta variables cuantitativas continuas en escala de razón. Su calidad es alta: no presenta valores faltantes ni registros duplicados, aunque incluye trece casos con ceros legítimos y un 3.56 % de valores atípicos asociados a tumores de gran tamaño.

Las variables no comparten escala y las diferencias entre ellas alcanzan varios órdenes de magnitud. Medida con el coeficiente de variación, la mayor dispersión corresponde al error estándar del área, con 112.78 %, y la menor a la dimensión fractal promedio, con 11.24 %. Existe además una redundancia importante, ya que 21 pares de variables superan una correlación de 0.90.

Tras estandarizar los datos, el análisis de componentes principales mostró que se requieren cinco componentes para explicar al menos el 80 % de la varianza y siete para alcanzar el 90 %. Los dos primeros reúnen el 63.24 %, suficiente para una representación visual pero no para sustituir al conjunto completo en un análisis cuantitativo.

PC1 se interpreta como un indicador general del tamaño y la irregularidad del núcleo celular, con cargas positivas repartidas entre las variables de radio, perímetro, área, concavidad y puntos cóncavos. PC2 contrasta la complejidad del contorno, encabezada por la dimensión fractal,

con las medidas de tamaño. La proyección de los casos sobre ambos componentes separa con claridad los diagnósticos benignos de los malignos sin haber utilizado esa información, lo que confirma que la reducción de dimensiones conservó la estructura esencial del conjunto.

REFERENCIAS

- [1] W. N. Street, W. H. Wolberg y O. L. Mangasarian, "Nuclear feature extraction for breast tumor diagnosis", en *Proc. IS&T/SPIE Int. Symp. Electronic Imaging: Science and Technology*, vol. 1905, San José, CA, EUA, 1993, pp. 861–870.
- [2] W. H. Wolberg, W. N. Street y O. L. Mangasarian, "Breast Cancer Wisconsin (Diagnostic) Data Set", UCI Machine Learning Repository, 1995. [En línea]. Disponible: <https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic>
- [3] D. Dua y C. Graff, "UCI Machine Learning Repository", Universidad de California, Irvine, Escuela de Ciencias de la Información y la Computación, 2019. [En línea]. Disponible: <https://archive.ics.uci.edu/ml>
- [4] J. Han, M. Kamber y J. Pei, *Data Mining: Concepts and Techniques*, 3.^a ed. Waltham, MA, EUA: Morgan Kaufmann, 2012.
- [5] I. T. Jolliffe y J. Cadima, "Principal component analysis: a review and recent developments", *Philosophical Transactions of the Royal Society A*, vol. 374, n.º 2065, art. 20150202, 2016.
- [6] I. T. Jolliffe, *Principal Component Analysis*, 2.^a ed. Nueva York, NY, EUA: Springer, 2002.
- [7] J. W. Tukey, *Exploratory Data Analysis*. Reading, MA, EUA: Addison-Wesley, 1977.
- [8] F. Pedregosa et al., "Scikit-learn: Machine learning in Python", *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [9] W. McKinney, "Data structures for statistical computing in Python", en *Proc. 9th Python in Science Conf. (SciPy)*, Austin, TX, EUA, 2010, pp. 56–61.
- [10] C. R. Harris et al., "Array programming with NumPy", *Nature*, vol. 585, pp. 357–362, 2020.
- [11] J. D. Hunter, "Matplotlib: A 2D graphics environment", *Computing in Science & Engineering*, vol. 9, n.º 3, pp. 90–95, 2007.
- [12] H. Abdi y L. J. Williams, "Principal component analysis", *WIREs Computational Statistics*, vol. 2, n.º 4, pp. 433–459, 2010.
- [13] S. S. Stevens, "On the theory of scales of measurement", *Science*, vol. 103, n.º 2684, pp. 677–680, 1946.

- [14] H. F. Kaiser, "The application of electronic computers to factor analysis", *Educational and Psychological Measurement*, vol. 20, n.º 1, pp. 141–151, 1960.
- [15] R. B. Cattell, "The scree test for the number of factors", *Multivariate Behavioral Research*, vol. 1, n.º 2, pp. 245–276, 1966.
- [16] M. M. Mukaka, "A guide to appropriate use of correlation coefficient in medical research", *Malawi Medical Journal*, vol. 24, n.º 3, pp. 69–71, 2012.